Análise de Dados

UFCD 10811 Projeto Final

Formador António Francisco da Costa Machado

Projeto Final

Ana Fernandes
Anaïs Gilbert
Berlinda Caiongo

Faro, 8 de fevereiro de 2024

<u>Índice</u>

Introdução

No cativante universo do cinema, os dados podem revelar histórias tão intrigantes quanto as narrativas que se desenrolam na tela.

Nesta análise, mergulharemos numa jornada pelos bastidores cinematográficos, abordando conjuntos de dados que revelarão alguns segredos sobre o desempenho financeiro, preferências de género e a evolução temporal da sétima arte.

Neste relatório, vamos limpar, transformar dados e reproduzir alguns gráficos para podermos inferir conclusões acerca da base de dados escolhida.

Este relatório tem como objetivo principal explorar o fascinante conjunto de dados cinematográficos por meio de uma análise exploratória. Vale ressaltar que não há um resultado único ou correto a ser alcançado.

A ferramenta escolhida para a execução deste trabalho é o *Jupyter*, proporcionando uma plataforma interativa e eficaz para análise de dados com a linguagem de programação *Python*. Com o *Jupyter*, conseguimos combinar código, visualizações e texto explicativo num único ambiente, facilitando a exploração e interpretação dos dados do conjunto de filmes.

Por fim, a busca pelo conhecimento e aprimoramento são os motores que impulsionaram esta jornada analítica.

Análise de Dados

Dados

Google drive

```
# Access google drive to upload dataset
from google.colab import drive
drive.mount('/content/drive')

# https://saturncloud.io/blog/how-to-read-csv-to-dataframe-in-google-colab/
```

Libs

```
# Import the necessary libs
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import me
import ast
```

Upload and read dataset

Ilustração 1- Carregamento e leitura da base de dados.

Limpeza e transformação de dados

Summary of dataset in analysis

Ilustração 2- Demonstração sumária da base de dados.

method head used to quickly check the data's structure movies.head <bound method NDFrame.head of 0 {'id': 10194, 'name': 'Toy Story Collection', ... 30000000 NAN 65000000</pre> belongs_to_collection budget \ {'id': 119050, 'name': 'Grumpy Old Men Collect... {'id': 96871, 'name': 'Father of the Bride Col... 4 0 45461 NaN 45462 45463 NaN 0 45464 NaN 0 45465 NaN

Ilustração 3- Cabeçalhos, primeiras e últimas 5 linhas da base de dados.

```
movies.isnull().sum()
belongs_to_collection
                         40972
budget
genres
id
                             0
original_title
                             0
production_companies
                             3
release_date
                            87
revenue
                            6
runtime
                           263
title
                             6
dtype: int64
```

Ilustração 4- Verificação dos nulos.

```
movies.dtypes
belongs_to_collection
                        object
budget
                        object
genres
                        object
id
                        object
original_title
                        object
production_companies
                        object
release_date
                        object
                        float64
revenue
runtime
                       float64
title
                        object
dtype: object
```

Ilustração 5- Verificação do tipo de dados da base de dados.

```
# Show the sum of how many duplicates are
movies.duplicated().sum()
```

30

Ilustração 6- Verificação de duplicados.

```
movies = movies.drop_duplicates()
movies.shape
(45436, 10)
```

Ilustração 7- Remoção de duplicados.

Genres column had empty arrays [] on the rows

```
[13] # drop the values that have both [] in the genres column and 0 revenue
  movies = movies.drop(movies['genres'] == '[]') & (movies['revenue'] == 0)].index)
  # replace the [] in the genres column with 0 for better visibility (0 = no genres associated)
  movies['genres'] = movies['genres'].replace('[]', 0)
  # check if there's any value left with [] in the genres column
  movies[movies['genres'] == '[]']
```

belongs_to_collection budget genres id original_title production_companies release_date revenue runtime title

Ilustração 8- Limpeza da coluna "genres".

production_companies column had empty arrays [] on the rows

```
[14] # replace the [] in the production_companies column with 0 for better visibility
    movies['production_companies'] = movies['production_companies'].replace('[]', 0)
    # check if there's any value left with [] in the prodyction_companies column
    movies[movies['production_companies'] == '[]']
```

belongs_to_collection budget genres id original_title production_companies release_date revenue runtime title

Ilustração 9- Limpeza da coluna "production_companies".

```
# check if there's either [] or {} value in "belongs_to_collection" column
movies[movies['belongs_to_collection'] == '[]']
movies[movies['belongs_to_collection'] == '{}']

belongs_to_collection budget genres id original_title production_companies release_date revenue runtime title
```

Ilustração 10- Verificação se coluna "belongs_to_collection" possui alguma lista vazia, seja {} ou [].

```
movies.shape

(43017, 10)

# replace empty values from the column budget with 0
movies['budget'] = movies['budget'].replace(0, np.nan)
```

Ilustração 11- Verificação da limpeza da base de dados.

```
# drop any row that doesn't contain only numbers in the budget column
movies = movies.drop(movies[~movies['budget'].str.isnumeric()].index)
# convert budget from string to float
movies['budget'] = movies['budget'].astype(float)
# convert id from object to int
movies['id'] = movies['id'].astype(int)
# convert release_date to datetime
movies['release_date'] = pd.to_datetime(movies['release_date'], errors='coerce')
movies.dtvpes
belongs_to_collection
                                     obiect
budget
genres
                                     obiect
id
                                      int64
original_title
                                     object
production_companies
                                     object
release_date
                          datetime64[ns]
revenue
                                   float64
runtime
                                    float64
                                     object
dtype: object
```

Ilustração 12- Conversão do tipo de dados para budget (objeto para float64), id (objeto para int) e release_date (objeto para datetime).

Ilustração 13- Renomeação da coluna "id" para "movie id" e verificação de todas as colunas.

```
import ast
\dot{\text{m}} def clean_genres(x): Defines a function clean_genres that takes an input x.
def clean genres(x):
      "" Checks if x is a string and not NaN.
        It uses isinstance to ensure that x is a string, and pd.notna checks if it's not NaN."""
    if isinstance(x, str) and pd.notna(x):
    """ This line is a list comprehension that processes the 'genres' column.
         It uses ast.literal_eval to safely evaluate the string representation of a list of dictionaries,
         replaces single quotes with double quotes to make it compatible with JSDN format,
         and extracts the 'name' values after stripping leading and trailing whitespaces.
        return [genre['name'].strip() for genre in ast.literal_eval(str(x).replace("'", "\""))]
        \# Returns an empty list if x is not a valid string.
        return []
""" This line applies the clean_genres function to each element in the 'genres' column using the apply method,
creating a new column named 'cleaned_genres' in the DataFrame. "
movies['cleaned_genres'] = movies['genres'].apply(clean_genres)
# Assigns the values of 'cleaned_genres' to the 'genres' column, effectively replacing it.
movies['genres'] = movies['cleaned_genres']
# Removes the temporary 'cleaned_genres' column from the DataFrame.
movies.drop('cleaned_genres', axis=1, inplace=True)
# Display the updated DataFrame
movies['genres']
```

```
0 [Animation, Comedy, Family]
1 [Adventure, Fantasy, Family]
2 [Romance, Comedy]
3 [Comedy, Drama, Romance]
4 [Comedy]
...
45459 [Science Fiction]
45460 [Drama, Action, Romance]
45461 [Drama, Family]
45462 [Drama]
45463 [Action, Drama, Thriller]
Name: genres, Length: 43014, dtype: object
```

Ilustração 14- Extração dos valores do campo 'name' em cada linha da coluna 'genres'".

```
# This function takes an input x, evaluates the 'belongs_to_collection' string into a dictionary, # and returns the 'name' value. If the input is NaN, it returns an empty string.

def extract_collection_name(x):
             return ast.literal_eval(str(x))['name']
  # Apply the function to create a new column 'collection_name'
movies['collection_name'] = movies['belongs_to_collection'].apply(extract_collection_name)
  # Replace 'belongs to collection' with 'collection name
  movies['belongs_to_collection'] = movies['collection_name']
  # Drop the temporary 'collection_name' column
movies.drop('collection_name', axis=1, inplace=True)
  # Display the result
  movies[['belongs_to_collection']]
              belongs_to_collection
  0
           Toy Story Collection
 2
           Grumpy Old Men Collection
   3
 4 Father of the Bride Collection
 45459
 45460
 45461
 45462
 45463
43014 rows × 1 columns
```

Ilustração 15- Extração de cada valor 'name' para cada linha na coluna 'belongs_to_collection' e separação apenas por vírgulas.

```
""" Handling Mixed types of data with a function inclunding a try except:
The try block attempts to execute the list comprehension to extract 'name' values
from the evaluated string representation of a list of dictionaries (ast.literal_eval(str(x))).
The except (ValueError, TypeError) block catches errors of type ValueError or TypeError that may occur during the evaluation.
These errors could happen if the content of 'production_companies' is not a valid string representation of a list of dictionaries.
def extract_production_companies_names(x):
      if pd.notna(x):
                 return [company['name'] for company in ast.literal eval(str(x))]
     except (ValueError, TypeError):
    return []
else:
           If an error is encountered during the evaluation, the function returns an empty list.
            This ensures that if the content of 'production_companies' is not in the expected format, the result will be an empty list instead of causing an error.
# Apply the function to create a new column 'production company names'
movies['production_companies_names'] = movies['production_companies'].apply(extract_production_companies_names)
# Display the result comparison
movies[['production_companies', 'production_companies_names']]
                                  production_companies production_companies_names
0 [{'name': 'Pixar Animation Studios', 'id': 3}]
                                                                                      [Pixar Animation Studios]
               [('name': 'TriStar Pictures', 'id': 559], ('na... [TriStar Pictures, Teitler Film, Interscope Co...
        [{name': 'Warner Bros.', 'id': 6194}, {name'... [Warner Bros., Lancaster Gate]
[{name': 'Twentieth Century Fox Film Corporat... [Twentieth Century Fox Film Corporation]
2
4 [['name': 'Sandollar Productions', 'id': 5842}... [Sandollar Productions, Touchstone Pictures]
45459 [['name': 'Concorde-New Horizons', 'id': 4688]] [Concorde-New Horizons]
45460 [{'name': 'Westdeutscher Rundfunk (WDR)', 'id'... [Westdeutscher Rundfunk (WDR), Working Title F.
45462
                        [{'name': 'Sine Olivia', 'id': 19653}]
                                                                                                        [Sine Olivia]
45463 [{name': 'American World Pictures', 'id': 6165}] [American World Pictures]
```

Ilustração 16- Extração apenas dos nomes em cada linha da coluna "production_companies" e comparação.

Assign values from the new column to the original 'production_companies' column movies['production_companies_names'] # Drop the old column which is now called production_companies_names movies_drop('production_companies', axis=1, inplace=True) movies Toy Story Collection 30000000 [Animation, Comedy, Family] 882 Toy Story 1995 1995 revenue runtime title production companies names Toy Story 1995-10-30 373554033.0 81.0 Toy Story 65000000.0 [Adventure, Fantasy, Family] 1995-12-15 262797249.0 Jumanji Jumanji [TriStar Pictures, Teitler Film, Interscope Co.. Grumpier Old Men [Warner Bros., Lancaster Gate] **2** Grumpy Old Men Collection 0.0 [Romance, Comedy] 15602 Grumpier Old Men 1995-12-22 0.0 101.0 16000000.0 [Comedy, Drama, Romance] 31357 Waiting to Exhale 127.0 Waiting to Exhale 4 Father of the Bride Collection 0.0 [Comedy] 11862 Father of the Bride Part II 1995-02-10 76578911.0 106.0 Father of the Bride Part II [Sandollar Productions, Touchstone Pictures] 45459 0.0 [Science Fiction] 222848 Caged Heat 3000 1995-01-01 0.0 85.0 Caged Heat 3000 [Concorde-New Horizons] 45460 0.0 [Drama, Action, Romance] 30840 Robin Hood 1991-05-13 0.0 104.0 Robin Hood [Westdeutscher Rundfunk (WDR), Working Title F.. 0.0 [Drama, Family] 439050 رگــعواب NaT 0.0 90.0 Subdue 45461 п 45462 [Drama] 111109 Siglo ng Pagluluwal 2011-11-17 360.0 Century of Birthing 0.0 [Action, Drama, Thriller] 67758 Betrayal 2003-08-01 0.0 90.0 Betrayal [American World Pictures] 45463 43014 rows × 10 columns

Ilustração 17- Substituição da coluna antiga pela nova, contendo apenas os nomes extraídos.

| | movieId as the index of movies.set_index('movie | | and sort the index in ascendex() | ding order | | | | | |
|---------|--|------------|---|-------------------------------------|--------------|-------------|---------|-------------------------------------|---|
| movieId | belongs_to_collection | budget | genres | original_title | release_date | revenue | runtime | title | production_companies_names |
| 2 | | 0.0 | [Drama, Crime] | Ariel | 1988-10-21 | 0.0 | 69.0 | Ariel | [Villealfa Filmproduction Oy, Finnish Film Fou |
| 3 | | 0.0 | [Drama, Comedy] | Varjoja paratiisissa | 1986-10-16 | 0.0 | 76.0 | Shadows in Paradise | [Villealfa Filmproduction Oy] |
| 5 | | 4000000.0 | [Crime, Comedy] | Four Rooms | 1995-12-09 | 4300000.0 | 98.0 | Four Rooms | [Miramax Films, A Band Apart] |
| 6 | | 0.0 | [Action, Thriller, Crime] | Judgment Night | 1993-10-15 | 12136938.0 | 110.0 | Judgment Night | [Universal Pictures, Largo Entertainment, JVC \dots |
| 11 | Star Wars Collection | 11000000.0 | [Adventure, Action, Science Fiction] | Star Wars | 1977-05-25 | 775398007.0 | 121.0 | Star Wars | [Lucasfilm, Twentieth Century Fox Film Corpora |
| | | | | | | | | | |
| 465044 | | 0.0 | [Fantasy, Drama] | Abduction | 2017-06-28 | 0.0 | 90.0 | Abduction | 0 |
| 467731 | | 0.0 | [Drama] | Tragedy in a Temporary Town | 1956-02-19 | 0.0 | 60.0 | Tragedy in a Temporary Town | 0 |
| 468343 | | 0.0 | [Drama, Romance] | Silja - nuorena nukkunut | 1956-01-01 | 0.0 | 87.0 | Silja - nuorena nukkunut | 0 |
| 468707 | | 1254040.0 | [Romance, Comedy] | Lauri Mäntyvaaran tuuheet ripset | 2017-07-28 | 0.0 | 90.0 | Thick Lashes of Lauri Mäntyvaara | [Elokuvayhtiö Oy Aamu] |
| 469172 | | 0.0 | [Fantasy, Drama] | Manoel dans l'île des merveilles | 1984-08-02 | 0.0 | 130.0 | Manuel on the Island of Wonders | [Institut National de l'Audiovisuel (INA), Rad |

Ilustração 18- Visão geral da base de dados após limpeza.

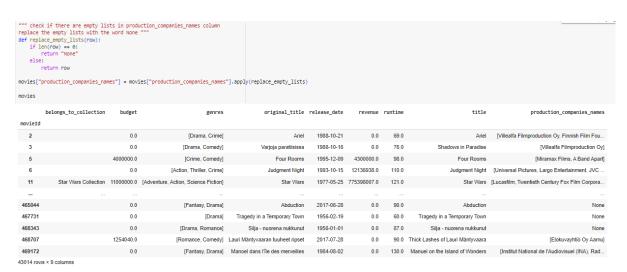


Ilustração 19- Verificação das linhas da coluna 'production_companies_names' que possuem listas vazias e substituição por "None".

```
# check if the genres column has any empty list
movies[movies["genres"].str.len() == 0]
# replace the empty lists with the word None
movies["genres"] = movies["genres"].apply(replace_empty_lists)
```

Ilustração 20- Verificação se a coluna "genres" e a coluna "production_companies_names" possuiem alguma lista vazia.

```
movies[movies['runtime'] == '']

belongs_to_collection budget genres original_title release_date revenue runtime title production_companies_names

movietd
```

Ilustração 21- Verificação de valores vazios na coluna "runtime".

```
# check if there are any rows that have 0 in the runtime column AND also 0 in the revenue column AND also 0 in the budget column movies[(movies['runtime'] == 0) & (movies['revenue'] == 0) & (movies['budget'] == 0)]
# drop the rows that have 0 in the runtime column AND also 0 in the revenue column AND also 0 in the budget column movies = movies.drop(movies[(movies['runtime'] == 0) & (movies['revenue'] == 0) & (movies['budget'] == 0)].index)
```

Ilustração 22- Verificação se há alguma linha no conjunto de dados que tenha o valor 0 na coluna"runtime", 0 na coluna "revenue" e também 0 na coluna "budget".

```
# Remove null values from the dataset with the method dropna()
movies = movies.dropna()
```

Ilustração 23- Remoção dos valores nulos da base de dados.

```
movies.isnull().sum()
belongs_to_collection
budget
                               0
genres
                               0
original_title
                               0
release date
                               0
revenue
                               0
runtime
                               0
title
                               0
production_companies_names
dtype: int64
```

Ilustração 24- Verificação se todos os nulos foram removidos da base de dados.

```
movies.dtypes
belongs_to_collection
                                      object
budget
                                     float64
genres
                                      object
original title
                                      object
release date
                              datetime64[ns1
                                     float64
revenue
runtime
                                     float64
title
                                      object
production_companies_names
                                      object
dtype: object
```

Ilustração 25- Verificação se os tipos de dados estão corretos.

Análise estatística e visualização de dados

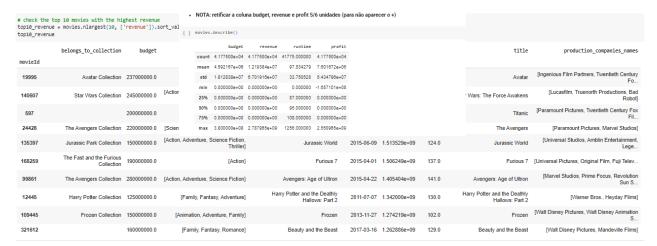


Ilustração 27- Lista dos 10 filmes com maior receita.

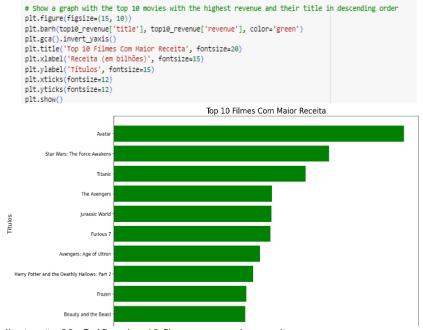


Ilustração 28- Gráfico dos 10 filmes com maior receita.

| p10_budg | | idget]).sort | _values(by='budget', ascending=False) | | | | | | |
|----------|-------------------------------------|---------------|--|---|--------------|--------------|---------|---|---|
| | belongs_to_collection | budget | genres | original_title | release_date | revenue | runtime | title | production_companies_names |
| ovieId | | | | | | | | | |
| 1865 F | Pirates of the Caribbean Collection | 380000000.0 | [Adventure, Action, Fantasy] | Pirates of the Caribbean: On Stranger Tides | 2011-05-14 | 1.045714e+09 | 136.0 | Pirates of the Caribbean: On Stranger Tides | [Walt Disney Pictures, Jerry Bruckheimer Films |
| 285 F | Pirates of the Caribbean Collection | 300000000.0 | [Adventure, Fantasy, Action] | Pirates of the Caribbean: At World's End | 2007-05-19 | 9.610000e+08 | 169.0 | Pirates of the Caribbean: At World's End | [Walt Disney Pictures, Jerry Bruckheimer Films. |
| 99861 | The Avengers Collection | 280000000.0 | [Action, Adventure, Science Fiction] | Avengers: Age of Ultron | 2015-04-22 | 1.405404e+09 | 141.0 | Avengers: Age of Ultron | [Marvel Studios, Prime Focus, Revolution Sun S. |
| 1452 | Superman Collection | 270000000.0 | [Adventure, Fantasy, Action, Science Fiction] | Superman Returns | 2008-08-28 | 3.910812e+08 | 154.0 | Superman Returns | [DC Comics, Legendary Pictures, Warner Bros., |
| 38757 | Tangled Collection | 260000000.0 | [Animation, Family] | Tangled | 2010-11-24 | 5.917949e+08 | 100.0 | Tangled | [Walt Disney Pictures, Walt Disney Animation S |
| 49529 | | 260000000.0 | [Action, Adventure, Science Fiction] | John Carter | 2012-03-07 | 2.841391e+08 | 132.0 | John Carter | [Walt Disney Pictures |
| 35988 | Transformers Collection | 260000000.0 | [Action, Science Fiction, Thriller, Adventure] | Transformers: The Last Knight | 2017-08-21 | 6.049421e+08 | 149.0 | Transformers: The Last Knight | [Paramount Pictures, Di Bonaventura Pictures, |
| 559 | Spider-Man Collection | 258000000.0 | [Fantasy, Action, Adventure] | Spider-Man 3 | 2007-05-01 | 8.908716e+08 | 139.0 | Spider-Man 3 | [Columbia Pictures, Laura Ziskin Productions, |
| 57201 | | 255000000.0 | [Action, Adventure, Western] | The Lone Ranger | 2013-07-03 | 8.928991e+07 | 149.0 | The Lone Ranger | [Walt Disney Pictures, Jerry Bruckheimer Films |
| 767 | Harry Potter Collection | 250000000.0 | [Adventure, Fantasy, Family] | Harry Potter and the Half-Blood Prince | 2009-07-07 | 9.339592e+08 | 153.0 | Harry Potter and the Half-Blood Prince | [Warner Bros., Heyday Films |

Ilustração 29 - Lista dos 10 filmes com os maiores orçamentos gastos.

```
# show a graph with the top 10 movies with the highest budget and their title in descending order plt.figure(figsize=(15, 10))
plt.barh(top10_budget['title'], top10_budget['budget'], color='red')
plt.gca().invert_yaxis()
plt.title('Top 10 Filmes Com Maior Gastos Na Produção', fontsize=20)
plt.xlabel('Gastos (em bilhões)', fontsize=15)
plt.ylabel('Titulos', fontsize=15)
plt.xticks(fontsize=12)
plt.yticks(fontsize=12)
plt.show()

Top 10 Filmes Com Maior Gastos Na Produção
```

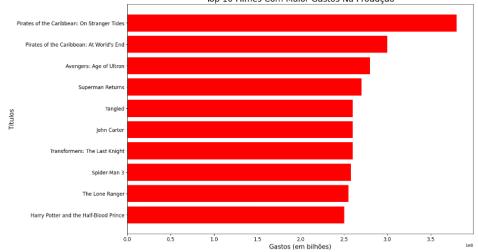


Ilustração 30- Gráfico dos 10 filmes com maiores gastos de produção.

| movies['profit # check the to | c'] = movies['revenue'] - m up 10 movies with the highe | novies['budget est profit | rence between revenue and budget '] alues(by='profit', ascending=False) | | | | | | Τ ψ ∞ Щ | φ β∎: |
|----------------------------------|---|------------------------------|---|---|--------------|--------------|---------|---|---|--------------|
| movieId | belongs_to_collection | budget | genres | original_title | release_date | revenue | runtime | title | <pre>production_companies_names</pre> | profit |
| 19995 | Avatar Collection | 237000000.0 | [Action, Adventure, Fantasy, Science Fiction] | Avatar | 2009-12-10 | 2.787965e+09 | 162.0 | Avatar | [Ingenious Film Partners, Twentieth Century Fo | 2.550965e+09 |
| 140607 | Star Wars Collection | 245000000.0 | [Action, Adventure, Science Fiction, Fantasy] | Star Wars: The Force Awakens | 2015-12-15 | 2.068224e+09 | 138.0 | Star Wars: The Force Awakens | [Lucasfilm, Truenorth Productions, Bad Robot] | 1.823224e+09 |
| 597 | : | 200000000.0 | [Drama, Romance, Thriller] | Titanic | 1997-11-18 | 1.845034e+09 | 194.0 | Titanic | [Paramount Pictures, Twentieth Century Fox Fil | 1.645034e+09 |
| 135397 | Jurassic Park Collection | 150000000.0 | [Action, Adventure, Science Fiction, Thriller] | Jurassic World | 2015-08-09 | 1.513529e+09 | 124.0 | Jurassic World | [Universal Studios, Amblin Entertainment, Lege | 1.383529e+09 |
| 168259 | The Fast and the Furious Collection | 190000000.0 | [Action] | Furious 7 | 2015-04-01 | 1.506249e+09 | 137.0 | Furious 7 | [Universal Pictures, Original Film, Fuji Telev | 1.316249e+09 |
| 24428 | The Avengers Collection | 220000000.0 | [Science Fiction, Action, Adventure] | The Avengers | 2012-04-25 | 1.519558e+09 | 143.0 | The Avengers | [Paramount Pictures, Marvel Studios] | 1.299558e+09 |
| 12445 | Harry Potter Collection | 125000000.0 | [Family, Fantasy, Adventure] | Harry Potter and the Deathly Hallows: Part 2 | 2011-07-07 | 1.342000e+09 | 130.0 | Harry Potter and the Deathly Hallows: Part 2 | [Warner Bros., Heyday Films] | 1.217000e+09 |
| 99861 | The Avengers Collection | 280000000.0 | [Action, Adventure, Science Fiction] | Avengers: Age of Ultron | 2015-04-22 | 1.405404e+09 | 141.0 | Avengers: Age of Ultron | [Marvel Studios, Prime Focus, Revolution Sun S | 1.125404e+09 |
| 109445 | Frozen Collection | 150000000.0 | [Animation, Adventure, Family] | Frozen | 2013-11-27 | 1.274219e+09 | 102.0 | Frozen | [Walt Disney Pictures, Walt Disney Animation S | 1.124219e+09 |
| 321612 | | 160000000.0 | [Family, Fantasy, Romance] | Beauty and the Beast | 2017-03-16 | 1.262886e+09 | 129.0 | Beauty and the Beast | [Walt Disney Pictures, Mandeville Films] | 1.102886e+09 |

Ilustração 31- Lista dos 10 filmes com os maiores lucros.

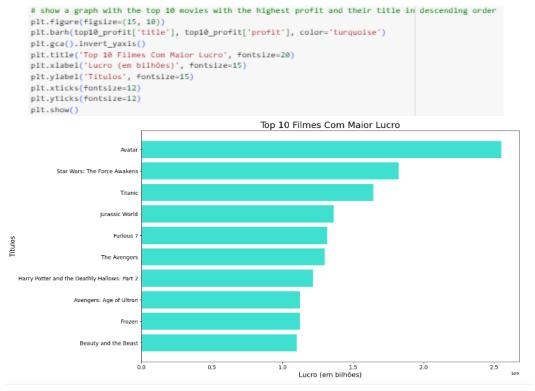


Ilustração 32- Gráfico dos 10 filmes com maior lucro.

Análise temporal

```
# check which genres had the highest profit in 2014
# check which genres had the highest profit in 2014
movies_2014 = movies[movies['release_date'].dt.year == 2014]
genres_profit_2014 = movies_2014[['genres', 'profit']]
genres_profit_2014['genre'] = genres_profit_2014['genres'].str[0].fillna('None')
genres_profit_2014.drop('genres', axis=1, inplace=True)
genres_profit_2014 = genres_profit_2014.groupby('genre')['profit'].sum().sort_values(ascending=False)
 genres_profit_2014
 <ipython-input-103-507d15b12026>:4: SettingWithCopyWarning:
A value is trying to be set on a copy of a slice from a DataFrame. 
Try using .loc[row_indexer,col_indexer] = value instead
See the caveats in the documentation: https://pandas.pydata.org/pandas-docs/stable/user_guide/indexing.html#returning-a-view-versus-a-copy
genres_profit_2014['genre'] = genres_profit_2014('genres'].str[0].fillna('None')

(ipython-input-103-507d15b12026>:5: SettingWithCopyWarning:
A value is trying to be set on a copy of a slice from a DataFrame
See the caveats in the documentation: <a href="https://pandas.pydata.org/pandas-docs/stable/user_guide/indexing.html@returning-a-view-versus-a-copy">https://pandas.pydata.org/pandas-docs/stable/user_guide/indexing.html@returning-a-view-versus-a-copy genres_profit_2014.drop('genres', axis=1, inplace=True)</a>
 Action
                                4.809746e+09
Science Fiction 2.413860e+09
Adventure 2.032072e+09
Conedy
                               1.565960e+09
Fantasy
                               1.267066e+09
Drama
Horror
                               1.004977e+09
7.160307e+08
                                7.053295e+08
 Animation
                               6.376184e+08
                                 6.121422e+08
 Romance
                                5.436533e+08
Family
                                5.394328e+08
 Mystery
History
                                2.931815e+08
2.386371e+08
Crime
                                1.618383e+08
Music
                                1.135663e+07
                                 3.540245e+06
0.000000e+00
 Documentary
 Foreign
TV Movie
                                 0.000000e+00
                               -3.899978e+85
Name: profit, dtype: float64
```

Ilustração 33- Géneros de filmes que lucraram mais em 2014.

Ilustração 34- Filme com mais lucros em 2016.

```
# check which genre was produced the most movies in the year 2017
movies_2017 = movies(movies('release_date').dt.year == 2017) # create a list with all the genres from the movies released in 2017
genres_2017 = []
for genre in movies_2017['genres']:
    genres_2017.extend(genre)
\ensuremath{\mbox{\sc \#}} count the number of times each genre appears in the list
from collections import Counter
genre_count_2017 = Counter(genres_2017)
genre_count_2017
# create a DataFrame with the genres and their respective counts
genre_count_2017 = pd.DataFrame(genre_count_2017.items(), columns=['Genre', 'Count'])
# sort the DataFrame in descending order
genre_count_2017 = genre_count_2017.sort_values(by='Count', ascending=False)
genre_count_2017
# show a graph with the number of movies produced for each genre in 2017
plt.figure(figsize=(15, 10))
plt.barh(genre_count_2017['Genre'], genre_count_2017['Count'], color='blue')
plt.gca().invert_yaxis()
plt.title('Número de Filmes Produzidos Por Género Em 2017', fontsize=20)
plt.xlabel('Número de Filmes', fontsize=15)
plt.ylabel('Gënero', fontsize=15)
plt.xticks(fontsize=12)
plt.yticks(fontsize=12)
plt.show()
```

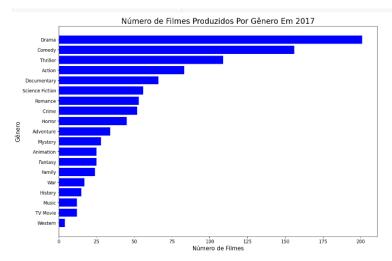


Ilustração 36- Gráfico do número de filmes produzidos por género em 2017.

See the caveats in the documentation: https://pandas.pydata.org/pandas-docs/stable/user_guide/indexing.html@returning-a-view-versus-a-copy genres_profit.drop('genres', axis=1, inplace=True)

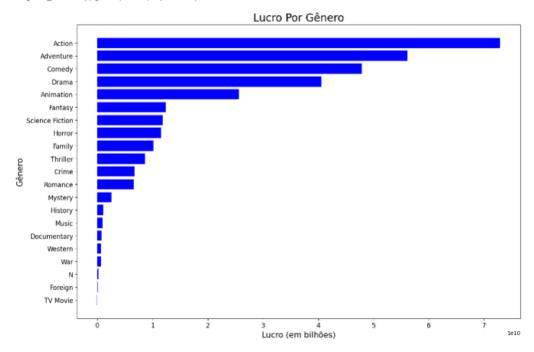
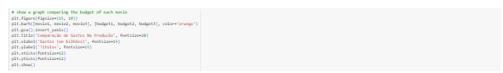


Ilustração 37- Gráfico de lucro por género de filme.

Análise de receitas vs orçamento da trilogia "The Hobbit"

```
# Defining variables for each movie from the trilogy
movie1 = 'The Hobbit: An Unexpected Journey'
movie2 = 'The Hobbit: The Desolation of Smaug
movie3 = 'The Hobbit: The Battle of the Five Armies'
# Get the budget for each movie and print the title and budget
budget1 = movies[movies['title'] == movie1]['budget'].values[0]
budget2 = movies[movies['title'] == movie2]['budget'].values[0]
budget3 = movies[movies['title'] == movie3]['budget'].values[0]
print(f"The movie '{movie1}' had a budget of ${budget1} USD.")
print(f"The movie '{movie2}' had a budget of {budget2} USD.")
print(f"The movie '{movie3}' had a budget of {budget3} USD.")
# Calculate and print the total budget spent on The Hobbit trilogy
total_budget = budget1 + budget2 + budget3
print(f"The total budget spent on The Hobbit trilogy was: ${total_budget} USD.")
The movie 'The Hobbit: An Unexpected Journey' had a budget of $250000000.0 USD.
The movie 'The Hobbit: The Desolation of Smaug' had a budget of 250000000.0 USD. The movie 'The Hobbit: The Battle of the Five Armies' had a budget of 250000000.0 USD.
The total budget spent on The Hobbit trilogy was: $750000000.0 USD.
```



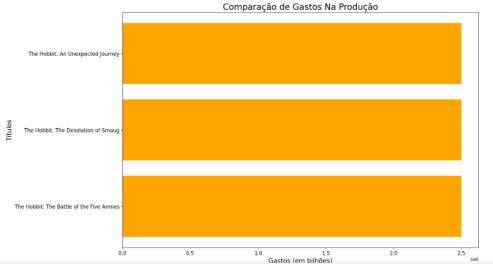


Ilustração 38- Gráfico da comparação dos gastos de cada filme da trilogia "The Hobbit".

```
# Get the revenue for each movie and print the title and corresponding revenue (without the budget calculated yet)

revenue1 = movies[movies['title'] == movie1]['revenue'].values[0]

revenue2 = movies[movies['title'] == movie2]['revenue'].values[0]

print(f"The movie '(movies['title'] == movie3]['revenue'].values[0]

print(f"The movie '(movies]' had a revenue of (revenue1) USD without counting the budget spent.")

print(f"The movie '(movie3)' had a revenue of (revenue3) USD without counting the budget spent.")

print(f"The movie '(movie3)' had a revenue of (revenue3) USD without counting the budget spent.")

# Calculate and print the total budget spent on The Hobbit trilogy

total revenue = revenue1 + revenue2 + revenue3

print(f"The total budget spent on The Hobbit trilogy was: $(total_revenue) USD.")

The movie 'The Hobbit: An Unexpected Journey' had a revenue of 1821103568.0 USD without counting the budget spent.

The movie 'The Hobbit: The Batlation of Smaug' had a revenue of 9584000000.0 Without counting the budget spent.

The movie 'The Hobbit: The Batlation of Smaug' had a revenue of 958019788.0 USD without counting the budget spent.

The total budget spent on The Hobbit trilogy was: $2935523356.0 USD.
```

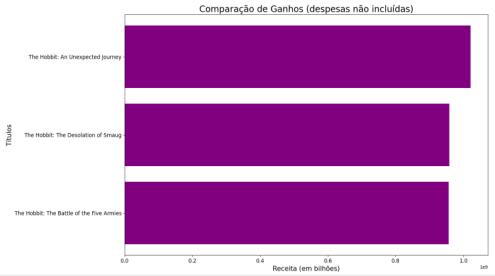


Ilustração 39- Gráfico da comparação dos ganhos, sem despesas incluídas, de cada filme da trilogia "The Hobbit".

```
# Get the profit made for each movie and print the title and profit in descending
profit1 = movies[movies['title'] == movie1]['profit'].values[0]
profit2 = movies[movies['title'] == movie2]['profit'].values[0]

profit3 = movies[movies['title'] == movie3]['profit'].values[0]

print(f"The movie '{movie1}' made a profit of ${profit1} USD.")
print(f"The movie '{movie2}' made a profit of ${profit2} USD.")

# Calculate and print the total profit made by The Hobbit trilogy
total_profit = profit1 + profit2 + profit3
print(f"The total profit made by The Hobbit trilogy was: ${total_profit} USD.")
```

The movie 'The Hobbit: An Unexpected Journey' made a profit of \$771103568.0 USD. The movie 'The Hobbit: The Desolation of Smaug' made a profit of \$708400000.0 USD. The movie 'The Hobbit: The Battle of the Five Armies' made a profit of \$706019788.0 USD. The total profit made by The Hobbit trilogy was: \$2185523356.0 USD.

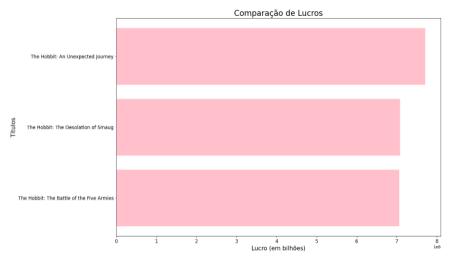


Ilustração 40- Gráfico da comparação dos lucros de cada filme da trilogia "The Hobbit".

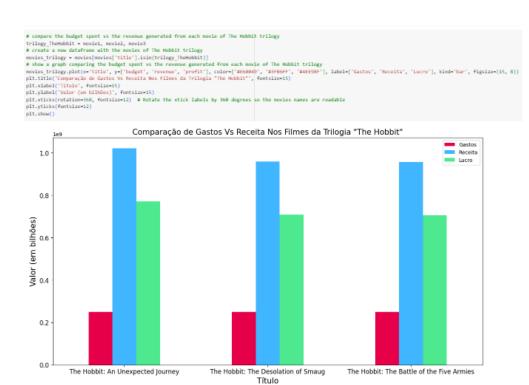


Ilustração 41- Gráfico da comparação de gastos vs receita nos filmes da trilogia "The Hobbit".

Conclusão

Com a realização das diversas etapas de análise de dados no conjunto de dados de filmes, foi possível tirar algumas conclusões significativas sobre a indústria cinematográfica. Através da limpeza de dados, identificamos e tratamos valores ausentes, eliminamos duplicados e garantimos que os tipos de dados fossem apropriados para cada coluna. Deste modo, obtivemos um conjunto de dados mais consistente e confiável para análise.

Ao realizar estatísticas descritivas, pudemos calcular variáveis numéricas para entender melhor a distribuição das variáveis-chave, como a receita de bilheteria. Isso proporcionou-nos insights valiosos sobre o desempenho médio dos filmes e a sua variabilidade.

Como análise geral identificamos os 10 filmes com maior receita (Avatar, Star Wars: The Force Awakens, Titanic, The Avengers, Jurassic World, Furious 7, Avengers: Age of Ultron, Harry Potter and the Deathly Hallows: Part 2, Frozen e Beauty and the Beast); os 10 filmes com maiores gastos de produção (Pirates of the Caribbean: On Stranger Tides, Pirates of the Caribbean: At World's End, Avengers: Age of Ultron, Superman Returns, Tangled, John Carter, Transformers: The Last Knight, Spider-Man 3, The Lone Ranger e Harry Potter and the Half-Blood Prince) e os 10 filmes com maior lucro (Avatar, Star Wars: The Force Awakens, Titanic, Jurassic World, Furious 7, The Avengers, Harry Potter and the Deathly Hallows: Part 2, Avengers: Age of Ultron, Frozen e Beauty and the Beast).

Na análise temporal, examinamos a evolução do mercado cinematográfico ao longo do tempo, em específico em determinado ano, observando mudanças nas tendências de receita e popularidade de diferentes géneros, por exemplo.

Assim, segundo a avaliação realizada, os géneros de filme que mais lucraram em 2014 foram: ação; ficção científica; aventura; comédia; fantasia; drama; terror; guerra; animação; entre outros. O filme que mais lucrou em 2016 foi o "Captain America: Civil War". Os géneros mais produzidos em 2017 foram: drama; comédia; suspense; ação; documentário; ficção científica; romance; crime; terror; aventura; entre outros. Os filmes que mais lucraram por género foram: ação; aventura; comédia; drama; animação; fantasia; ficção científica; terror; família; suspense; entre outros. Por fim, a "Marvel Studios" produziu até 2017 24 filmes no total.

Por fim, na análise de receitas versus orçamento, exploramos a relação entre essas duas variáveis para a trilogia "The Hobbit". Deste modo, o valor gasto na produção de cada filme foi de 250 milhões, perfazendo o total gasto de 750 milhões de dólares. A receita, sem contar com os gastos, para o filme "The Hobbit: An Unexpected Journey" foi de 1021103568 dólares, para o "The Hobbit: The Desolation of Smaug" foi de 958400000 dólares e para o "The Hobbit: The Battle of the Five Armies" foi de 956019788 dólares, tendo um total de 2935523356 dólares em receitas. O lucro para o filme "The Hobbit: An Unexpected Journey" foi de 771103568 dólares, para o "The Hobbit: The Desolation of Smaug" foi de 708400000 dólares e para o "The Hobbit: The Battle of the Five Armies" foi 706019788 dólares, perfazendo um total de 2185523356 de dólares de lucro. Assim, após comparação, o filme que mais rendeu da trilogia foi o primeiro filme "The Hobbit: An Unexpected Journey".

Através da visualização de dados, criamos gráficos claros e informativos para representar a distribuição das variáveis-chave como os gastos, a receita de bilheteria e os lucros. Essas visualizações ajudaram-nos a identificar padrões e tendências de forma mais intuitiva das avaliações realizadas.

Concluindo, as etapas de análise de dados forneceram uma compreensão mais profunda e abrangente da indústria cinematográfica.

Investigações e análises que poderiam ser efetuadas futuramente:

- Seleção e criação de novas características que possam influenciar as receitas dos filmes, como indicadores de popularidade do elenco ou do realizador.
- Modelagem de Machine Learning através da avaliação e seleção de modelos de ML apropriados para a previsão de receitas de filmes, tais como regressão linear, árvores de decisão ou modelos de aprendizagem profunda.
- Treino e validação dos modelos, recorrendo a técnicas como validação cruzada para garantir a generalização.
- Avaliação e Seleção do Modelo através da avaliação do desempenho dos modelos usando métricas de avaliação adequadas para problemas de regressão, como erro médio absoluto (EMA) ou erro quadrático médio (EQM). Comparação dos modelos e seleção do mais adequado com base nas métricas de avaliação. Implementação do modelo selecionado num ambiente de produção para efetuar previsões de receitas de filmes em tempo real.
- Monitorização contínua do desempenho do modelo e realização de ajustes conforme necessário para garantir a sua precisão e relevância ao longo do tempo.

Webgrafia

Github

https://www.kaggle.com/datasets/rounakbanik/the-movies-dataset
https://saturncloud.io/blog/how-to-read-csv-to-dataframe-in-google-colab/
https://docs.jupyter.org/en/latest/

 $\underline{\text{https://pandas.pydata.org/docs/user guide/dsintro.html}}$

https://matplotlib.org/stable/users/explain/quick_start.html

https://chat.openai.com/